

1. **Promtail:** Агент збору логів, який монтується до `/var/lib/docker/containers` хоста, автоматично зчитує логи всіх контейнерів, додає метадані (назву контейнера, сервісу) та відправляє їх у Loki.
2. **Grafana Loki:** Горизонтально масштабована база даних логів. Виступає центральним сховищем текстової інформації для всієї системи.
3. **Prometheus:** Система збору та зберігання часових рядів (метрики). Збирає метрики з експортерів (Node, MySQL, Nginx) та оцінює правила алертів (наприклад, MySQLDown).
4. **Alertmanager:** Обробляє алерти від Prometheus та AI-адаптера, групує їх, виконує дедуплікацію та направляє на Webhook Telegram-бота.
5. **Ollama:** Self-hosted платформа для запуску великих мовних моделей. Завдяки інтеграції з NVIDIA Container Toolkit виконує інференс моделі **Llama-3 (8B)** з апаратним прискоренням на GPU хост-машини.
6. **AI-Adapter (Python):** Фоновий мікросервіс, який періодично робить вибірку останніх логів безпеки з Loki за допомогою LogQL, відправляє їх до Ollama для виявлення аномалій та у разі високого рівня загрози (`risk_score >= 7`) генерує алерт в Alertmanager.
7. **Telegram Bot (Python/FastAPI):** Отримує алерти від Alertmanager. Для стандартних інфраструктурних алертів він самостійно зчитує логи з Loki, запитує аналіз у LLM та відправляє розширені результати власнику у чат.

LLM (Llama-3) у цій архітектурі виконує дві критичні функції:

A. Асинхронне виявлення загроз (Streaming Log Scanning)

AI-адаптер регулярно (щохвилини) зчитує сирі логи доступу та додатків. Модель аналізує їх на наявність: * Спроб SQL-ін'єкцій (SQLi) * Спроб віддаленого виконання команд (RCE) * Атак типу brute-force (перебір паролів) * Міжсайтового скриптингу (XSS)

На виході модель класифікує загрозу за **10 найбільш вірогідними категоріями**: 1. **SQL Injection** 2. **Remote Code Execution** 3. **Brute-force Attack** 4. **Cross-Site Scripting** 5. **Unauthorized Access** 6. **Database Connection Failure** 7. **Out of Memory Crash** 8. **High Error Rate** 9. **Service Timeout** 10. **Resource Exhaustion**

Також визначається оцінка ризику (risk_score від 0 до 10). Якщо оцінка перевищує 7, створюється інцидент.

Б. Збагачення контексту сповіщень (On-the-fly Alert Enrichment)

Коли спрацьовує стандартний алерт (наприклад, база даних MySQL не відповідає), розробнику зазвичай приходить просте повідомлення `MySQL database is DOWN`.

Завдяки інтеграції з LLM: 1. Бот перехоплює сповіщення. 2. Робить швидкий запит до Loki для отримання останніх 10-15 рядків логів впалого контейнера. 3. Передає ці логи до Llama-3 з промптом виявити причину. 4. Модель аналізує помилки (наприклад, знаходить `Out of memory: Killed process` або `Access denied for user`) та формує: * **Точну ідентифікацію проблеми** (наприклад, `Out of Memory Crash`). * **Розширене резюме (Summary)** людською мовою, де пояснює, чому це сталося. * **Рекомендації (Mitigation Steps)** (наприклад, збільшити ліміт пам'яті в compose-файлі або перевірити права користувача бд).

Це суттєво скорочує час на розслідування інцидентів (MTTR - Mean Time to Resolution), оскільки інженер отримує готову діагностику та інструкції з ліквідації проблеми безпосередньо у месенджері.