

SecOps AI Monitoring Stack Architecture

Даний документ описує архітектуру, взаємодію компонентів та роль локальної мовної моделі (LLM) у системі автоматизованого моніторингу безпеки та аналізу аномалій.

1. Схема потоку даних (Data Flow)

Система побудована на принципі реактивного моніторингу та проактивного сканування логів:

```
flowchart TD
    %% Application Stack Components
    subgraph AppStack [Application Stack]
        WP[WordPress Container] --> PT[Promtail]
        NG[Nginx Proxy Container] --> PT
        DB[MySQL Container] --> PT
    end

    %% Monitoring Stack Components
    PT --> LK[Grafana Loki]
    ME[MySQL Exporter] --> PR[Prometheus]
    NE[Node Exporter] --> PR
    NXE[Nginx Exporter] --> PR

    %% AI Analysis Pipeline
    subgraph AI_Analysis [AI Analysis Pipeline]
        AA[AI Adapter] --> LK
        LK --> AA
        AA --> OL[Ollama: Llama-3 GPU]
        OL --> AA
        AA --> AM[Alertmanager]
    end

    %% Notification Pipeline
    subgraph Notification [Notification Pipeline]
        AM --> TG[Telegram Bot Container]
        TG --> LK
        LK --> TG
        TG --> OL
        OL --> TG
        OL --> Mitigation[Mitigation JSON]
        Mitigation --> TGA[Telegram API]
    end
```

2. Компоненти системи та їх ролі

1. **Promtail**: Агент збору логів, який монтується до `/var/lib/docker/containers` хоста, автоматично зчитує логи всіх контейнерів, додає метадані (назву контейнера, сервісу) та відправляє їх у Loki.
2. **Grafana Loki**: Горизонтально масштабована база даних логів. Виступає центральним сховищем текстової інформації для всієї системи.
3. **Prometheus**: Система збору та зберігання часових рядів (метрики). Збирає метрики з експортерів (Node, MySQL, Nginx) та оцінює правила алертів (наприклад, `MySQLDown`).
4. **Alertmanager**: Обробляє алерти від Prometheus та AI-адаптера, групує їх, виконує дедуплікацію та направляє на Webhook Telegram-бота.
5. **Ollama**: Self-hosted платформа для запуску великих мовних моделей. Завдяки інтеграції з NVIDIA Container Toolkit виконує інференс моделі **Llama-3 (8B)** з апаратним прискоренням на GPU хост-машини.
6. **AI-Adapter (Python)**: Фоновий мікросервіс, який періодично робить вибірку останніх логів безпеки з Loki за допомогою LogQL, відправляє їх до Ollama для виявлення аномалій та у разі високого рівня загрози (`risk_score >= 7`) генерує алерт в Alertmanager.
7. **Telegram Bot (Python/FastAPI)**: Отримує алерти від Alertmanager. Для стандартних інфраструктурних алертів він самостійно зчитує логи з Loki, запитує аналіз у LLM та відправляє розширені результати власнику у чат.

3. Роль мовної моделі (LLM) у моніторингу

LLM (Llama-3) у цій архітектурі виконує дві критичні функції:

A. Асинхронне виявлення загроз (Streaming Log Scanning)

AI-адаптер регулярно (щохвилини) зчитує сирі логи доступу та додатків. Модель аналізує їх на наявність: * Спроб SQL-ін'єкцій (SQLi) * Спроб віддаленого виконання команд (RCE) * Атак типу brute-force (перебір паролів) * Міжсайтового скриптингу (XSS)

На виході модель класифікує загрозу за **10 найбільш вірогідними категоріями**: 1. **SQL Injection** 2. **Remote Code Execution** 3. **Brute-force Attack** 4. **Cross-Site Scripting** 5. **Unauthorized Access** 6. **Database Connection Failure** 7. **Out of Memory Crash** 8. **High Error Rate** 9. **Service Timeout** 10. **Resource Exhaustion**

Також визначається оцінка ризику (`risk_score` від 0 до 10). Якщо оцінка перевищує 7, створюється інцидент.

Б. Збагачення контексту сповіщень (On-the-fly Alert Enrichment)

Коли спрацьовує стандартний алерт (наприклад, база даних MySQL не відповідає), розробнику зазвичай приходить просте повідомлення `MySQL database is DOWN`.

Завдяки інтеграції з LLM: 1. Бот перехоплює сповіщення. 2. Робить швидкий запит до Loki для отримання останніх 10-15 рядків логів впалого контейнера. 3. Передає ці логи до Llama-3 з промптом виявити причину. 4. Модель аналізує помилки (наприклад, знаходить `Out of memory: Killed process` або `Access denied for user`) та формує: * **Точну ідентифікацію проблеми** (наприклад, `Out of Memory Crash`). * **Розширене резюме (Summary)** людською мовою, де пояснює, чому це сталося. * **Рекомендації (Mitigation Steps)** (наприклад, збільшити ліміт пам'яті в compose-файлі або перевірити права користувача бд).

Це суттєво скорочує час на розслідування інцидентів (MTTR - Mean Time to Resolution), оскільки інженер отримує готову діагностику та інструкції з ліквідації проблеми безпосередньо у месенджері.